Módulo de Importación mediante Web Scraping

> **Asignatura:** 3641 - Bases de Datos Aplicada
>
> **Comisión: 02-5600**
>
> **Proyecto:** Sistema de Registro y Gestión del Mundial de Fútbol
>
> **Tecnología de Extracción:** Python

Para complementar los datasets estructurados del torneo y cumplir con el requerimiento de integración de fuentes no descargables directamente (como calendarios detallados, sedes o nóminas históricas), se desarrolló un módulo de extracción automatizada de datos (web scraping) utilizando el lenguaje de programación **Python**.

1. Arquitectura y Tecnologías Empleadas

- **Lenguaje:** Python (versión 3.x).
- **Librerías principales:** Se empleó `requests` para la gestión de peticiones HTTP seguras y `BeautifulSoup` (perteneciente a la librería `bs4`) para el análisis sintáctico y recorrido del árbol DOM de las páginas web de origen.
- **Página de origen:** Wikipedia – “List of FIFA World Cup referees” (histórico de árbitros).

2. Flujo de Ejecución y Procesamiento

El proceso de extracción se divide en tres etapas principales:

- **Extracción y Conexión HTTP:** El script establece una conexión remota mediante una petición `GET`, simulando cabeceras estándar de navegación para asegurar una recepción correcta del código fuente HTML.
- **Parsing y Limpieza de Datos:** Mediante selectores estructurados, se aíslan las tablas o bloques informativos clave. Los datos recopilados se depuran en memoria, eliminando espacios redundantes, caracteres especiales y registros incompletos.
- **Estructuración y Generación del Archivo:** Una vez depurados, los datos se exportan y estructuran en un archivo CSV llamado `arbitros.csv` generado por el propio script de Python.

3. Integración con el Motor de Base de Datos (Lógica de Upsert)

La información procesada y contenida en el archivo `arbitros.csv` ingresa al motor SQL Server a través de Stored Procedures específicos. Estos componentes implementan la lógica de **Upsert** (verificando la existencia previa de la clave de negocio para decidir entre una inserción o una actualización), garantizando que no se generen registros duplicados y manteniendo la consistencia histórica del sistema ante múltiples ejecuciones.